

基于 SIFT 特征提取的非刚性医学图像配准算法研究

王安娜 吕 丹[△] 王 哲 方志珍

(东北大学 信息科学与工程学院, 沈阳 110004)

摘 要: 针对医学图像的非刚性配准, 给出一种实用的特征点匹配算法——基于尺度不变特征变换(SIFT)进行特征提取的图像配准算法。该算法利用图像特征在尺度空间具有平移、旋转和仿射变换不变性, 提取图像的特征点。选择双向匹配算法建立特征间点的匹配关系, 提高配准精度。在此基础上, 根据仿射变换实现图像的非刚性配准, 并采用归一化互信息测度和 PSO 优化算法优化图像配准过程。实验结果显示, 相对于基于互信息的图像配准方法, 该配准方法可以得到较好的图像配准结果。

关键词: 非刚性配准; 尺度不变特征变换; 双向匹配; 仿射变换; PSO

中图分类号 TP39 **文献标识码** A **文章编号** 1001-5515(2010)04-0763-06

Research on Non-rigid Medical Image Registration Algorithm Based on SIFT Feature Extraction

Wang Anna Lu Dan Wang Zhe Fang Zhizhen

(College of Information Science and Engineering, Northeastern University, Shenyang 110004 China)

Abstract In allusion to non-rigid registration of medical images, the paper gives a practical feature points matching algorithm—the image registration algorithm based on the scale-invariant features transform (Scale Invariant Feature Transform, SIFT). The algorithm makes use of the image features of translation, rotation and affine transformation invariance in scale space to extract the image feature points. Bidirectional matching algorithm is chosen to establish the matching relations between the images, so the accuracy of image registrations is improved. On this basis, affine transform is chosen to complement the non-rigid registration, and normalized mutual information measure and PSO optimization algorithm are also chosen to optimize the registration process. The experimental results show that the method can achieve better registration results than the method based on mutual information.

Key words: Non-rigid registration; Scale invariant feature transform (SIFT); Bidirectional matching; Affine transform; PSO

引言

医学图像配准是医学图像融合的前提, 是目前医学图像处理中的热点之一, 具有重要的临床诊断和治疗价值。图像配准与融合技术在病灶定位、医学影像存档与通信系统、放射治疗计划、指导神经手术以及检查治疗效果上有着重要的应用价值。因此, 图像配准技术作为图像融合的前提和关键技术越来越受到广泛的关注。

图像配准的方法有很多, 其中基于图像特征的配准方法是图像配准中最常见的方法, 而基于特征的图像配准中, 特征主要是针对点特征。基于特征

点的图像配准是计算机视觉领域中一个研究热点, 有着广阔的应用前景。医学图像的非刚性配准在医学诊断和治疗计划中起着重要的作用, 学者们为此提出了多种非刚性配准算法。近年来提出的典型非刚性配准算法有^[1]: 使用基本函数配准; 使用样条配准, 包括薄板样条和 B 样条; 基于物理模型的配准; 流体配准; FEM (有限元) 配准; 应用光流场的配准方法等。

尺度不变特征变换 (scale invariant feature transform, SIFT) 匹配算法^[2,3]是目前国内外特征匹配研究领域取得比较成功的一种算法, 该算法匹配能力较强, 能提取稳定的特征, 可以处理两幅图像之间发生平移、旋转、仿射变换、视角变换、光照变换情况下的匹配问题, 甚至在某种程度上对任意角度拍

[△] 通讯作者, E-mail: qingtian1128@yahoo.com.cn

摄的图像也具备较为稳定的特征匹配能力, 从而可以实现差异较大的两幅图像之间特征的匹配。

1 图像特征点提取和特征匹配

1.1 SIFT 特征提取

特征点提取是图像配准的关键步骤, 本文选用 SIFT 特征提取算法进行特征点的提取。该算法实现的主要步骤包括:

(1) 尺度空间极值点的检测

为了实现特征点对图像尺度的不变性, 需要对图像根据不同的采样距离进行采样以形成一个金字塔分层结构, 并对各组图像采用不同的高斯滤波因子进行滤波形成高斯金字塔分层结构; 将每组中相邻图像相减生成高斯差分图像 (DOG), 在高斯差分金字塔分层结构中提取极值点作为候选特征点。

为了寻找尺度空间中存在的极值点, 需要把每个采样点要和它周围所有的相邻点进行比较, 即比较它是否比周围图像域和尺度域的相邻像素点大或者小。每个样本点不仅要与本层中相邻的 8 个像素点比较, 还要与上下相邻两层中各 9 个像素点进行比较, 即共需要与 26 个像素进行比较。

尺度空间理论最早出现于计算机视觉领域, 目的是为了模拟图像数据的多尺度特征。高斯卷积核是实现尺度变换的唯一线性核, 二维图像的尺度空间定义为

$$L(x, y, \sigma) = G(x, y, \sigma) \otimes I(x, y), \quad (1)$$

其中 \otimes 为卷积运算, $G(x, y, \sigma)$ 为尺度可变高斯函数, σ 称为尺度空间因子。

$$G(x, y, \sigma) = \frac{1}{2\pi\sigma^2} \exp[-(x^2 + y^2)/2\sigma^2], \quad (2)$$

为了在尺度空间上检测到稳定的特征点, 需要采用高斯差分尺度空间 (DOG), 即将不同尺度的高斯差分核和图像进行卷积, 其中 k 是常数。

$$D(x, y, \sigma) = (G(x, y, k\sigma) - G(x, y, \sigma)) \otimes I(x, y) = L(x, y, k\sigma) - L(x, y, \sigma), \quad (3)$$

(2) 特征点位置的确定

$$m(x, y) = \sqrt{(L(x+1, y) - L(x-1, y))^2 + (L(x, y+1) - L(x, y-1))^2}, \quad (7)$$

$$\theta(x, y) = \arctan \left[\frac{L(x, y+1) - L(x, y-1)}{L(x+1, y) - L(x-1, y)} \right]$$

(4) 特征描述符的生成

图 1 中左部分的中央位置为当前特征点的位置, 每个小方格表示该特征点窗口图像所在尺度空间的一个像素, 圆圈代表了高斯加权的范围。在每

为了精确定位极值点的位置, 需要去除对比度比较低的特征点以及不稳定的边缘响应点, 以增强匹配的稳定性, 并提高抗噪声能力。

将尺度空间函数 $D(x, y, \sigma)$ 进行泰勒级数展开 (最高到 2 次项):

$$D(x) = D + \frac{\partial D}{\partial x} x + \frac{1}{2} x^T \frac{\partial^2 D}{\partial x^2} x, \quad (4)$$

其中 $x = (x, y, \sigma)^T$ 为样本点的偏移量, 求这个函数的导数可以得到 x 的极值 \bar{x} 。

$$\bar{x} = \frac{\partial D^{-1}}{\partial x^2} \frac{\partial D}{\partial x}, \quad (5)$$

如果极值 \bar{x} 在任意方向上大于 0.5, 意味着偏移量的极值与另外的样本点非常接近, 样本点就会被改变, 这时用插值来代替该样本点。在极值处的函数值 $D(\bar{x})$ 对过滤具有低对比度的不稳定极值点是很有用的。

$$D(\bar{x}) = D + \frac{1}{2} \frac{\partial D}{\partial x} \bar{x}, \quad (6)$$

图像边缘的特征点在高斯差分函数的峰值处与边缘交叉处的主曲率值较大, 但在垂直方向上的曲率值较小, 可以利用这个性质将边缘处的低对比度特征点过滤掉^[2]。

(3) 特征点主方向的提取

利用特征点周围图像的梯度方向分布统计来确定特征点的主方向, 使得 SIFT 算子具有旋转不变的性能。式 (7) 为 (x, y) 处梯度的幅值和方向公式, 其中 L 所用的尺度为每个特征点各自所在的尺度。计算时需要对以特征点为中心的窗口图像进行采样, 根据直方图统计窗口图像内所有像素的梯度方向。梯度直方图统计范围是 $0 \sim 360^\circ$, 选择直方图的峰值代表该特征点处邻域梯度的主方向, 同时作为特征点的主方向。在梯度方向直方图中, 如果存在另一个峰值, 且该峰值相当于主峰值的 80%, 可以把这个方向看作特征点的辅方向。一个特征点可以提取多个方向 (例如一个主方向和一个辅方向), 大大增强特征点匹配时的鲁棒性。

4×4 的小块内计算出 8 个方向的梯度方向直方图, 并统计每个梯度方向的累计值, 得到一个种子点, 如图 1 右部分所示。图中一个特征点由 2×2 共 4 个种子点构成, 每个种子点会有 8 个方向的向量值。

采用邻域方向统计和加权, 一方面是增强了算法抗噪声的能力, 另一方面对定位误差的特征匹配提供了较好的稳定性。为了进一步增强特征匹配的鲁棒性, 可以对每个特征点使用 4×4 共 16 个种子点的方式进行特征描述, 每个特征点可以产生 128 维的特征数据, 即 128 维的 SIFT 特征向量。此时 SIFT 特征向量已经去除了图像尺度、旋转等几何变形的影响, 如果对特征向量进行长度归一化, 就可以进一步去除图像灰度变化的影响。




图 1 生成特征描述符示意图
Fig. 1 Sketch map of feature descriptors

1.2 SIFT 特征向量匹配

寻找两幅或多幅图像间的对应点问题被称为图像特征点匹配。由于 SIFT 特征点提取算法提取出的特征点具有很高的鲁棒性, 同时又因为用 128 维的维度来对特征点进行描述, 使得特征点描述符之间具有很大的差异性, 所以就可以直接利用特征点之间的几何特性进行特征点的匹配: 查找每个特征点的 2 个近似最近邻特征点, 这里的最近邻定义为特征描述符向量间的最小欧氏距离。如果最近距离除以次近距离小于某个比例阈值, 则接受这一对匹配点。

为了进一步去除错误匹配, 提高匹配准确率, 本文采用双向匹配算法^[4]: 基于上述第一次匹配结果, 反过来求第二个特征集中已被匹配的特征点在第一个特征集中的匹配点, 即求已被匹配的特征点在第一个特征集中的最近邻与次近邻的距离比, 比值小于设定阈值的匹配点才认为是正确的匹配点对。

2 图像配准

2.1 几何模型

本文采用双线性插值^[5]的反映射仿射变换, 进行空间坐标变换。仿射变换可以通过一系列变换的复合来实现, 包括: 缩放、旋转、平移和剪切。此类变换可以用一个 3×3 的矩阵来表示, 其最后一列为

$(0, 0, 1)$ 。该变换矩阵将原坐标 (x, y) 变换为新坐标 (x', y') , 这里原坐标和新坐标皆为最后一列为 $(0, 0, 1)$ 的三维行向量, 原行向量右乘变换矩阵得到新的行向量:

$$[x' \ y' \ 1] = [x \ y \ 1] \begin{bmatrix} t_{11} & t_{12} & 0 \\ t_{21} & t_{22} & 0 \\ t_{31} & t_{32} & 1 \end{bmatrix}, \quad (8)$$

在图像配准中, 首先根据标准图像与待配准图像对应点的坐标, 求解两幅图像之间的变换参数; 然后将待配准图像做相应的空间变换, 使两幅图像处于同一坐标系下; 最后通过灰度变换, 对空间变换后的待配准图像的灰度值进行重新赋值, 即重采样, 来完成图像配准。

2.2 相似性测度

相似性测度的选择很大程度上依赖于特征空间的选择, 合适的相似性测度能有效地提高配准的速度和精度。互信息测度首次用于医学图像配准中, 随后研究者们对它进行了大量的研究。当两幅图像的空间位置达到一致时, 其中一幅图像表达另一幅图像的信息, 即其互信息为最大。设 A 为待配准图像, B 为标准图像, 边缘概率分别为 $P_A(a)$ 和 $P_B(b)$, 联合概率分布为 $P_{AB}(a, b)$, 互信息为 $MI(A, B)$:

$$MI(A, B) = H(A) + H(B) - H(A, B) = - \sum_{a,b} P_{AB}(a, b) \cdot \log \frac{P_{AB}(a, b)}{P_A(a) \cdot P_B(b)}, \quad (9)$$

本文选择归一化互信息 (normalized mutual information, NMI) 测度, 它是比互信息更为稳定的、其它一些形式的熵测度:

$$NMI(A, B) = \frac{H(A) + H(B)}{H(A, B)}, \quad (10)$$

2.3 粒子群优化算法

寻优是在选择了一种相似性测度以后采用优化算法使该测度达到最优值的过程, 本文选择粒子群 (Particle Swarm Optimization, PSO)^[6,7] 优化算法。PSO 优化算法是一种基于群体进化的全局优化算法, 它能够获得近似最优的全局解; 其寻优过程不依赖梯度信息, 而且搜索效率高, 具有很强的鲁棒性。

PSO 算法在描述个体时, 将其看成是 D 维寻优搜索空间的一个没有质量和体积的微粒 (点), 结合微粒和群体的历史最佳位置信息, 以一定的速度向目标值逼近。设粒子 i 在 D 维空间里的位置用矢量 $X_i = [x_{i1}, x_{i2}, \dots, x_{iD}]$ 表示, 飞行速度用矢量 $V_i = [V_{i1}, V_{i2}, \dots, V_{iD}]$ 表示, 并将其延伸到 D 维空间。

每个粒子根据由适应函数决定的适应值,知道目前为止自己发现的最好位置(P_{best})和现在的位置 X_i , 及所有粒子发现的最好位置(g_{best})。粒子通过自己的经验和同伴中的最好经验来决定下一步的运动。第 i 个微粒从 k 代进化到 $k+1$ 代,通过下式进行更新:

$$v_{id}^{k+1} = wv_{id}^k + c_1r_1^k(P_{id} - x_{id}^k) + c_2r_2^k(P_{gd} - x_{id}^k), \tag{11}$$

$$x_{id}^{k+1} = x_{id}^k + v_{id}^{k+1}, \tag{12}$$

式中 x_{id}^k 为第 k 次迭代时粒子 i 位置矢量的第 d 维分量, P_{id} 为粒子 i 个体最好位置 P_{best} 的第 d 维分量, P_{gd} 为群体最好位置 g_{best} 的第 d 维分量, w 为惯性权重,有助于新区域的搜索, c_1 、 c_2 均为正实数,表示将每个微粒推向 P_{best} 和 g_{best} 的统计加速度的权重, r_1^k 、 r_2^k 为在区间[0, 1] 内变化的随机数。

PSO 算法的一般步骤如下: ①种群随机初始

化; ②对种群内的每一个个体计算适应值, 适应值与最优解的距离直接有关; ③种群根据适应值进行复制, 利用公式(11)和公式(12)进行最优解的更新; ④如果终止条件满足, 就停止, 否则转步骤②。

应用 PSO 解决问题的关键步骤在于: PSO 有关参数的设置和适应度函数的选择。使用匹配点对间的欧氏距离作为 PSO 的适应度函数, 通过 PSO 算法强大的搜索性能求出最优的仿射变换参数。

3 实验结果

3.1 图像特征点提取和特征匹配实验结果

根据 SIFT 特征提取方法对图像进行特征点的提取, 最终得到对每个特征点定义的特征描述符, 如图 2 所示。




图 2 特征点提取结果
(a)原图像; (b)高斯金字塔分层结构; (c)高斯差分金字塔分层结构; (d)特征描述符

Fig. 2 The result of feature points extraction
(a)original image; (b)Gaussian pyramid hierarchical structure; (c)Difference of Gaussian pyramid hierarchical structure; (d)Feature descriptors

实现特征点匹配时, 阈值的选择关系到最终得到匹配点对的正确性。根据文献[2]可知, 对于 0.8 以上的阈值来说, 图像匹配效果不好, 得到错误匹配

的概率极高。在实验中选择两个不同的阈值, 可以得到如图 3 和图 4 所示的两个不同的匹配结果。




图 3 特征点匹配结果(阈值=0.6)

Fig. 3 The matching result of feature points




图 4 特征点匹配结果(阈值=0.8)

Fig. 4 The matching result of feature points

3.2 图像配准实验结果

经过前面各个图像配准步骤的操作: 提取特征点, 得到匹配点对的坐标; 根据控制点的空间坐标, 建立图像间的映射关系, 得出仿射变换参数; 在得到两幅图像间的变换参数后, 要将输入图像做相应参数的变换使之与参考图像处于同一坐标系下, 会涉及到输入图像变换后所得点的坐标不一定为整数, 则应进行双线性插值处理。选用的相似性测度用来在给定的变换模型下得到最优变换参数, 而采用一定的优化措施可使相似性测度更快、更好地达到最优值。

评价配准算法的优劣主要考虑精度、准确度、稳定性、可靠性、算法的复杂性和临床可用性等因素, 其中前两个因素最为重要, 目前主要通过间接方法

进行评价。对于图像配准结果的评价指标, 由于技术还处于起步阶段, 尚无统一的评价指标, 本文就目前比较公认的指标进行了效果评价, 包括: 相关系数 (correlation coefficient, COEF)、归一化互信息 (normalized mutual information, NMI)、信噪比 (signal to noise ratio, SNR) 和最小均方误差 (mean squared error, MSE)。

经过上述的图像配准操作, 可以得到图 5、图 6 和图 7 所示配准结果, 并将文中选用的图像配准方法与基于互信息的图像配准方法进行比较。表 1、表 2 和表 3 是采用上述评价指标对三组图像配准结果进行评价得到的数据。对比表中的指标参数可知: 相对于基于互信息的配准方法, 文中提出的图像配准方法有一定的优越性, 图像配准效果相对较好。




图 5 第一组图像配准结果

(a) 标准图像; (b) 待配准图像; (c) 本文方法; (d) 互信息方法

Fig. 5 The first image registration results

(a)reference image; (b)float image; (c)the method in the paper; (d)mutual information method

表 1 第一组图像配准结果评价指标

| Tab. 1 The evaluations of the first image registration results | | | | |
|--|---------|----------|----------|---------|
| 指标 | 相关系数 | MSE | SNR | NMI |
| 本文方法 | 0. 8716 | 1724. 71 | 58. 7129 | 0. 4415 |
| 互信息方法 | 0. 6891 | 1946. 66 | 51. 9843 | 0. 3576 |

表 2 第二组图像配准结果评价指标

| Tab. 2 The evaluations of the second image registration results | | | | |
|---|---------|----------|----------|---------|
| 指标 | 相关系数 | MSE | SN R | NMI |
| 本文方法 | 0. 4292 | 1445. 56 | 18. 8287 | 0. 4094 |
| 互信息方法 | 0. 3461 | 1796. 48 | 17. 9752 | 0. 3485 |




图 6 第二组图像配准结果

(a)标准图像; (b)待配准图像; (c)本文方法; (d)互信息方法

Fig. 6 The second image registration results

(a)reference image; (b)float image; (c)the method in the paper; (d)m utual in formation method




图 7 第三组图像配准结果

(a)标准图像; (b)待配准图像; (c)本文方法; (d)互信息方法

Fig. 7 The third image registration results

(a)reference image; (b)float image; (c)the method in the paper; (d)m utual in formation method

表 3 第三组图像配准结果评价指标

| Tab. 3 The evaluations of the third image registration results | | | | |
|--|---------|----------|----------|---------|
| 指标 | 相关系数 | MSE | SNR | NMI |
| 本文方法 | 0. 5298 | 1839. 43 | 29. 9273 | 0. 7432 |
| 互信息方法 | 0. 4782 | 2301. 68 | 27. 5739 | 0. 6954 |

4 结论

为了实现图像配准中特征提取这一关键步骤, 论文应用了一种匹配能力较强的 SIFT 特征提取算法, 提取稳定的特征点。SIFT 算法的理论基础是通过高斯金字塔分层结构的形式来实现的, 在各个层次上进行特征点特征描述符的提取, 论文中求取

高斯差分函数 DOG 最大和最小值的方法能得到最稳定的图像特征点, 有助于算法的稳定; 对特征点方向的确定也是通过局部信息的统计特性进行主方向和辅方向的综合评估, 进一步提高了特征点提取的准确性。接下来采用双向匹配算法进行特征点匹配, 提高了图像匹配的准确率。同时, 采用双线性插值的仿射变换来进行空间变换, 并利用功能强大的 PSO 优化算法求出最优仿射变换参数来实现图像非刚性配准。由实验结果可知, 文中选用的方法在实现图像配准方面有一定的优越性。

(下转第 784 页; Continued on Page 784)

测的准确性,有效减少了预测数据的假阳性比例。

参 考 文 献

[1] MACHADO-LIMA A, DEL PORTILLO H A, DURHAM A M. Computational methods in noncoding RNA research[J] . Journal of Mathematical Biology, 2008, 56(1-2): 15-49.

[2] EDDY S. SQUID - C function library for sequence analysis. <http://selab.wustl.edu/cgi-bin/selab.pl?mode=software#squid>.

[3] WASHIETL S, HOFACKER I L. Consensus folding of aligned sequences as a new measure for the detection of functional RNAs by comparative genomics[J] . Journal of Molecular Biology, 2004, 342(1): 19-30.

[4] BABAK T, BLENCOWE B J, HUGHES T R. Considerations in the identification of functional RNA structural elements in genomic alignments[J] . BMC Bioinformatics, 2007, 8(1): 33.

[5] WANG C, DING C, MERAZ R F, et al. PSoL: A positive sample only learning algorithm for finding non-coding RNA genes[J] . Bioinformatics, 2006, 22(21): 2590-2596.

[6] TAX D M J, DUIN R P W. Support vector data description [J] . Mach Learn, 2004, 54(1): 45-66.

[7] VAPNIK V N. Statistical learning theory, II support vector estimation of functions[M] . New York: John Wiley and Sons, 1998: 375-567.

[8] VAPNIK V N. Nature of statistical learning theory, chapter 5 methods of pattern recognition[M] . New York: John Wiley and Sons, 2000: 123-167.

[9] KARLIN S, CAMPBELL A M, MRAZEK J. Comparative DNA analysis across diverse genomes[J] . Annu Rev Genet, 1998, 32(1): 185-225.

[10] HOFACKER I L, FEKETE M, STADLER P F. Secondary structure prediction for aligned RNA sequences[J] . Journal of Molecular Biology, 2002, 319(5): 1059-1066.

[11] LIU C, BAI B, SKOGERBO G, et al. NONCODE: an integrated knowledge database of non-coding RNAs[J] . Nucleic Acids Res, 2005, 33(1): D112-D115.

(收稿: 2009-04-27 修回: 2009-09-07)

(上接第 768 页; Continued from Page 768)

参 考 文 献

[1] 冯林, 管慧娟, 孙焘, 等. 医学图像非刚性配准研究进展[J] . 北京生物医学工程, 2005, 25(4): 437-439.

[2] LOWE D G. Distinctive image features from scale-invariant keypoints[J] . International Journal of Computer Vision, 2004, 60(2): 91-110.

[3] BROWN M, LOWE D G. Invariant features from interest point groups[C] . UK: British Machine Vision Conference, 2002: 656-665.

[4] 蹇森, 朱剑英. 基于改进的 SIFT 特征的图像双向匹配算法

[J] . 机械科学与技术, 2007, 26(9): 1179-1182.

[5] 李弼程, 彭天强, 彭波. 智能图像处理技术[M] . 北京: 电子工业出版社, 2004: 118-119.

[6] KENNEDY J, EBERHART R. Particle swarm optimization [C] . Australia Perth: IEEE Int Conf on Neural Networks, 1995: 1942.

[7] EBERHART R, KENNEDY J. A new optimizer using particle swarm theory[C] . Japan Nagoya: Proc of the Sixth International Symposium on Micro Machine and Human Science, 1995: 39.

(收稿: 2008-10-30 修回: 2009-09-04)